Project 3 - Fashion-MNIST Classification

1. Environment

```
import platform
import os
from platform import python_version
print('os name:',platform.system(),platform.release())
print('python version :',python_version())
print('torch version :',torch.__version__)
print('torchvision version :',torchvision.__version__)
print('matplotlib version :',matplotlib.__version__)
print('numpy version :',numpy.__version__)

os name: Linux 5.4.109+
python version : 3.7.10
```

python version : 3.7.10 torch version : 1.8.1+cu101 torchvision version : 0.9.1+cu101 matplotlib version : 3.2.2 numpy version : 1.19.5

OS: Linux 5.4.109
python version: 3.7.10
torch version: 1.8.1
torchvision version: 0.9.1

matplotlib version: 3.2.2

• numpy version: 1.19.5

2. Network architecture description

2-1 Fully Connected Network

```
class FC_Network(nn.Module):
    def __init__(self):
        super(FC_Network,self).__init__()
        self.fc1=nn.Linear(28*28,512,bias=True)
        self.fc2=nn.Linear(512,10,bias=True)
        self.relu=nn.ReLU()
        torch.nn.init.xavier_uniform_(self.fc1.weight)
        torch.nn.init.xavier_uniform_(self.fc2.weight)

    def forward(self,x):
        x=self.fc1(x.reshape(x.shape[0],-1))
        x=self.relu(x)
        x=self.fc2(x)
        return x
```

Fully connected network 은 nn.Module를 상속받아 생성했고, 구성은 차례로

- input size=784, output size=512 인 fully connected layer
- ReLU activation function
- input size=512, output size=10 인 fully connected layer

로 구성되어 있습니다.

Input data가 들어오게 되면, [batchsize,1,28,28]의 3차원의 형태로 각각의 이미지가 들어오기 때문에 fully connected layer를 통과하기 위해서 reshape을 통해서 [batchsize,784]의1차원 형태로 각각의 이미지를 변환되게 됩니다.

그 후에 fully connected layer에 의해 [batchsize,512]의 형태로 변환되게 되고, ReLU activation function을 통과하게 됩니다.

마지막으로 fully connected layer에 의해 [batchsize,10] 의 형태로 각각의 이미지에 대해 크기가 10인 vector의 형태로 output data가 생성됩니다.

2-2 LeNet-5

```
class Lenet_5(nn.Module):
 def __init__(self,softmax_exist=False,
              activation_function='tanh',
               first_channel=6.
              second_channel=16,
              third_channel=120,
              use_batchnorm=False,
              pooling_layer='avg',
              use_dropout=False):
   super(Lenet_5, self).__init__()
   self.con1=nn.Conv2d(in_channels=1,out_channels=first_channel,kernel_size=5,stride=1,padding=2)
   self.con2=nn.Conv2d(in_channels=first_channel,out_channels=second_channel,kernel_size=5,stride=1)
   self.con3=nn.Conv2d(in_channels=second_channel,out_channels=third_channel,kernel_size=5,stride=1)
   self.use_batchnormflag=use_batchnorm
   self.batchnorm1=nn.BatchNorm2d(first_channel)
   self.batchnorm2=nn.BatchNorm2d(second_channel)
   self.batchnorm3=nn.BatchNorm2d(third_channel)
   if activation_function=='tanh':
     self.activation_function=nn.Tanh()
   elif activation_function=='relu':
     self.activation_function=nn.ReLU()
   elif activation_function=='leaky_relu':
     self.activation_function=nn.LeakyReLU()
    if pooling_layer=='avg':
     self.pooling_layer=nn.AvgPool2d(2)
   elif pooling_layer=='max':
     self.pooling_layer=nn.MaxPool2d(2)
   self.fc1=nn.Linear(third_channel,84)
   self.fc2=nn.Linear(84,10)
   self.sflag=softmax_exist
   self.softmax=nn.Softmax(1)
   self.dflag=use_dropout
   self.dropout=nn.Dropout(0.3)
   torch.nn.init.xavier_uniform_(self.fc1.weight)
   torch.nn.init.xavier_uniform_(self.fc2.weight)
```

```
def forward(self.x):
  x=self.con1(x)
  if self.use_batchnormflag==True:
   x=self.batchnorm1(x)
  x=self.activation_function(x)
  x=self.pooling_layer(x)
  x=self.con2(x)
  if self.use_batchnormflag==True:
   x=self.batchnorm2(x)
  x=self.activation_function(x)
  x=self.pooling_layer(x)
  x=self.con3(x)
  if self.use_batchnormflag==True:
   x=self.batchnorm3(x)
  x=self.activation_function(x)
  x=x.reshape(x.shape[0],-1)
  x=self.fc1(x)
  if self.dflag:
   x=self.dropout(x)
  x=self.activation_function(x)
  x=self.fc2(x)
  if self.sflag:
   x=self.softmax(x)
  return x
```

LeNet-5은 전체적으로 3개의 convolutional layer와 2개의 fully connected layer로 구성되어 있고, nn.Module를 상속 받아서 생성했습니다. 구성은 차례로

- input channel=1, output channel=6, kernel size=5, stride=1, padding=2인 convolutional layer
- tanh activation function
- average pooling layer
- input channel=6, output channel=16, kernel size=5, stride=1, padding=0 [□] convolutional layer
- tanh activation function
- average pooling layer
- input channel=16, output channel=120, kernel size=5, stride=1, padding=0인 convolutional layer
- tanh activation function
- input size=120, output size=84 인 fully connected layer
- tanh activation function
- input size=84, output size=10 인 fully connected layer

로 구성되어 있습니다.

input data [batchsize,1,28,28] 가 들어오게 되면 LeNet-5 구조에서는 [1,32,32] 의 형태로 이미지가 들어와야 되기 때문에 첫번쨰 convolutional layer에서 padding을 2를 줘야 됩니다.

첫번째 convolutional layer를 통과하게 되면, [batchsize,6,28,28] 로 형태가 변하게 되고, tanh activation function과 크기 2짜리 average pooling layer를 통과하게 되면 [batchsize,6,14,14] 가 됩니다.

그후에 2번째 convolutional layer, tanh activation function, 크기 2짜리 average pooling layer를 통과 하게 되면 [batchsize,16,5,5] 의 형태가 변하게 됩니다.

마지막 convolution layer과 tanh activation function을 통과하게 되면 [batchsize,120,1,1]로 형태가 됩니다.

그후에 fully connected layer를 통과하기 위해서 이미지가 1차원의 형태로 변환하게 되서 [batchsize,120]로 바뀝니다.

첫번째 fully connected layer, tanh activation function을 통과하게 되면 [batchsize,84] 로 형태가 변하 게 되고

마지막 fully connected layer를 통과하게 되면서 최종적으로 [batchsize, 10] 의 형태로 가각의 이미지에 대해서 크기가 10인 vector의 형태로 output data 가 생성되게 됩니다.

모델을 정의하는 부분에 있어서 LeNet-5 의 학습율을 높이기 위해서 변수들을 받아서 모델을 설정할 수 있게 했습니다.

• softmax: True, False

MSELoss를 loss function으로 사용하는 경우, model의 마지막 layer에 softmax layer를 추가해야 되야 되서 설정값으로 추가할 수 있도록 했습니다. True로 설정되어 있는 경우, 모델의 마지막 layer에 softmax layer를 추가하게 됩니다.

• activation_function: 'tanh', 'relu', 'leaky_relu'

activation function 을 따로 지정할 수 있고, 기본값으로는 tanh 함수를 사용하고 있고, 설정에 따라서 tanh, relu, leaky relu를 activation 함수로 사용할 수 있습니다.

• first channel, second channel, third channel: int

first channel, second channel, third channel 는 각각 첫번째, 두번째, 세번째 convolutional layer에서 out channel에 해당하는 채널의 수이며, 설정에 따라 조정할 수 있게 했습니다.

• use_batchnorm: True, False

use_batchnorm이 설정되어 있는 경우, convolutional layer를 통과한 이후 batch normalization 을 진행하도록 설정했습니다.

• pooling_layer: 'avg', 'max'

pooling layer도 종류도 설정할 수 있게 하였습니다. average pooling layer 또는 max pooling layer를 사용할 수 있습니다.

use_dropout : True, False

use_dropout이 설정되어 있는경우, 첫번째 fully connected layer후에 dropout을 적용하도록 하였습니다.

3. loss function and optimizer

3-1 Fully Connected Layer - optimizer, loss function function

```
def train_FC(training_epoch,batch_size,learning_rate):
  device='cpu'
  if torch.cuda.is_available():
    device='cuda'
  print('using device :',device)
  train_data_loader,test_data_loader=get_loader(batch_size=batch_size)
  model=FC_Network().to(device)
  criterion=nn.CrossEntropyLoss().to(device)
  optimizer=torch.optim.Adam(model.parameters(), Ir=learning_rate)
  print('hyper parameter')
  print('training epoch :',training_epoch)
  print('batch_size :',batch_size)
  print('learning rate :',learning_rate)
  epoch_num=0
  loss_per_epoch=[]
  batch_len=len(train_data_loader)
  for epoch in range(training_epoch):
   epoch_num+=1
   training_loss=0
    for imgs, labels in train_data_loader:
      imgs=imgs.to(device)
      labels=labels.to(device)
      predictions=model(imas)
      loss_function=criterion(predictions,labels)
      optimizer.zero_grad()
      loss function.backward()
      optimizer.step()
      training_loss+=loss_function.item()/batch_len
   print('epoch :',epoch_num,'\ttraining_loss :',training_loss)
    loss_per_epoch.append(training_loss)
```

다음은 Fully Connected Layer를 학습시킬 때 사용한 코드이며, loss function으로는 CrossEntropyLoss 를 사용했으며, optimizer로는 Adam optimizer를 사용했습니다.

CrossEntropyLoss는 LogSoftmax 와 NLLLoss를 순차적으로 진행해서 나오는 loss 이며, 첫번째로

LOGSOFTMAX

```
CLASS torch.nn.LogSoftmax(dim=None)
```

[SOURCE]

Applies the $\log(\mathrm{Softmax}(x))$ function to an n-dimensional input Tensor. The LogSoftmax formulation can be simplified as:

$$\operatorname{LogSoftmax}(x_i) = \log \left(\frac{\exp(x_i)}{\sum_j \exp(x_j)} \right)$$

Logsoftmax 는 tensor의 각 element들의 지수승을 취해고, 차지하는 비율을 구한뒤 log를 취한 결과값 입니다.

그리고 NLLLoss 는 negative likelihood loss의 약자로, 분류 모델에서 자주 쓰이는 loss function이고, 각 target에 해당하는 class들에 대한 수치가 있는 tensor(logsoftmax로 도출된 tensor)와, 각 target들 에 해당하는 class index가 있는 tensor를 입력 받아서 loss를 계산합니다. Adam optimizer는 momentum과 root mean square propagation의 두가지 기법이 적용된 optimizer 로, momentum 개념을 활용해 gradient descent를 진행할때 momentum의 식을 따로 적용해서 weight update를 진행하게 되고, exponential moving average를 취해면서 weight update를 진행하게 됩니다.

3-2 LeNet-5 - optimizer, loss function function

```
#depending on the loss function, define criterion and choose whether softmax layer has to exist in the model if loss_function_name=='CrossEntropyLoss':
    criterion=nn.CrossEntropyLoss().to(device)
    softmax_exist=False
elif loss_function_name=='MultiMarginLoss':
    criterion=nn.MultiMarginLoss().to(device)
    softmax_exist=False
elif loss_function_name=='MSELoss':
    criterion=nn.MSELoss().to(device)
    softmax_exist=True
```

```
#depending on the optimizer name, define optimizer
if optimizer_name=='Adam':
   optimizer=torch.optim.Adam(model.parameters(), lr=learning_rate)
elif optimizer_name=='SGD':
   optimizer=torch.optim.SGD(model.parameters(), lr=learning_rate)
elif optimizer_name=='RMSprop':
   optimizer=torch.optim.RMSprop(model.parameters(), lr=learning_rate)
```

다음은 LeNet-5 구조에서 사용한 loss function 과 optimizer 입니다. task2에서 training element를 analyze하기 위해서 다양한 loss function과 optimizer를 사용할 수 있도록 구현했습니다.

MultiMarginLoss에서는 각 class들에 해당하는 수치들이 있는 2-D tensor 와 각각의 target class 들이 있는 1-D tensor를 입력받아서, 서로간의 hinge loss를 구하는 방식으로 loss를 정의합니다. 여기서 hinge loss는 margin의 개념을 이용해서 구하는 loss 이며, 0 과 margin-target_index value-index_value 중 큰 값을 취하면서 계산하게 됩니다.

MSELoss input과 target 의 mean squared error를 loss로 정의하며, 코드에서는 모델에서 output data 로 나오는 각 이미지에 대한 크기 10짜리 벡터와, 이미지에 해당하는 index를 one-hot encoding으로변 환한 벡터값 사이의 MSELoss를 계산했습니다. MSELoss를 사용할 경우,target class의 one hot encoding tensor 와 model의 output tensor의 loss를 구하게 되는데, one hot encoding tensor 의 결 과값이 0또는 1이므로, model의 output data 의 범위도 0에서 1사이의 값을 도출하도록 model의 마지막 layer에 softmax layer를 추가했습니다.

SGD optimizer은 data 를 1개를 본후 loss를 구해가면서 순차적으로 weight들을 업데이트 해주면서 loss function의 최솟값을 찾아가는 optimizer를 의미합니다.

RMSprop optimizer은 learning rate를 그대로 쓰지 않고, adaptive learning rate로 특정 수식을 통해 learning rate를 조정해 가면서 weight update를 진행하는 optimizer입니다.

```
for imgs, labels in train_data_loader:
    imgs=imgs.to(device)

#depending on the loss function, change which the label format to use(index/one hot encoding)
if loss_function_name=='CrossEntropyLoss':
    labels=labels.to(device)
elif loss_function_name=='MultiMarginLoss':
    labels=labels.to(device)
elif loss_function_name=='MSELoss':
    labels=torch.zeros(labels.shape[0],10).scatter_(1,labels.unsqueeze(1),1.).to(device)

predictions=model(imgs)
loss_function=criterion(predictions,labels)
optimizer.zero_grad()
loss_function.backward()
optimizer.step()
```

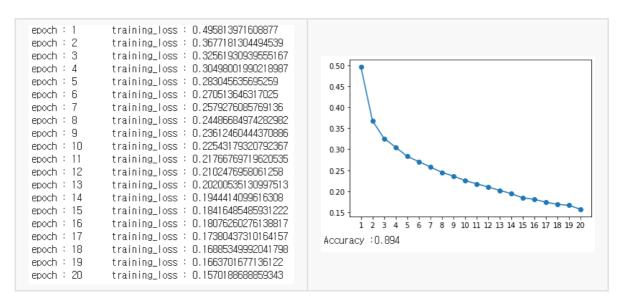
MSELoss를 사용할 경우, image 에 해당 하는 class index들을 one_hot encoding으로 변환한뒤 MSELoss를 계산했습니다.

3-3 optimizer and loss function concept

loss function 같은 경우, model에서 나온 output data와 target data의 차이의 지표를 나타내주며, loss function의 정의에 따라 data 에서 유사도를 나타나내는 지표를 바꿀 수있습니다. 이러한 loss function을 정의해 output data와 target data의 다른 정도를 나타냈다면, optimizer는 model의 parameter들을 조정해 최종적으로 loss function의 값을 줄여주는 역활을 합니다. optimizer의 정의 에 따라, loss function의 최솟값을 찾아갈때 그 알고리즘과 경로가 달라지게 되고, 최소 loss function값에 도달하기까지의 step 수가 달라지게 됩니다.

4. Screen-shot and analysis

4-1 Fully Connected Layer



다음은 Fully Connected Layer에서의 training loss, training loss graph와 test accuracy 입니다. Fully connected Layer를 학습 시킬때

training epoch: 20batch size: 100learning rate: 0.001

로 hyper parameter를 설정한 뒤 학습을 진행 했습니다. training loss 는 그래프에서 관찰한 바로는 계속 떨어지는 결과를 보였고, test data에 대한 accuracy는 89.4%로 나왔습니다.

4-2 LeNet-5

LeNet-5 구조에서는 base case 에서 model에 수정을 가하거나, hyper parameter에 변화를 주면서 학습을 진행해 봤고, 다음은 base case의 설정과 base case로 학습을 진행한 결과입니다.

training epoch: 20batch size: 100learning rate: 0.001optimizer type: Adam

• loss function : CrossEntropyLoss

• activation function: tanh

• first, second, third channel in convolutional layers: 6,16,120

pooling layer: average pooling layer

• no scheduler, no batch normalization, no dropout layer



training loss 는 0.16 까지 떨어졌고, test data에 대한 accuracy는 89.24%로 나왔습니다.

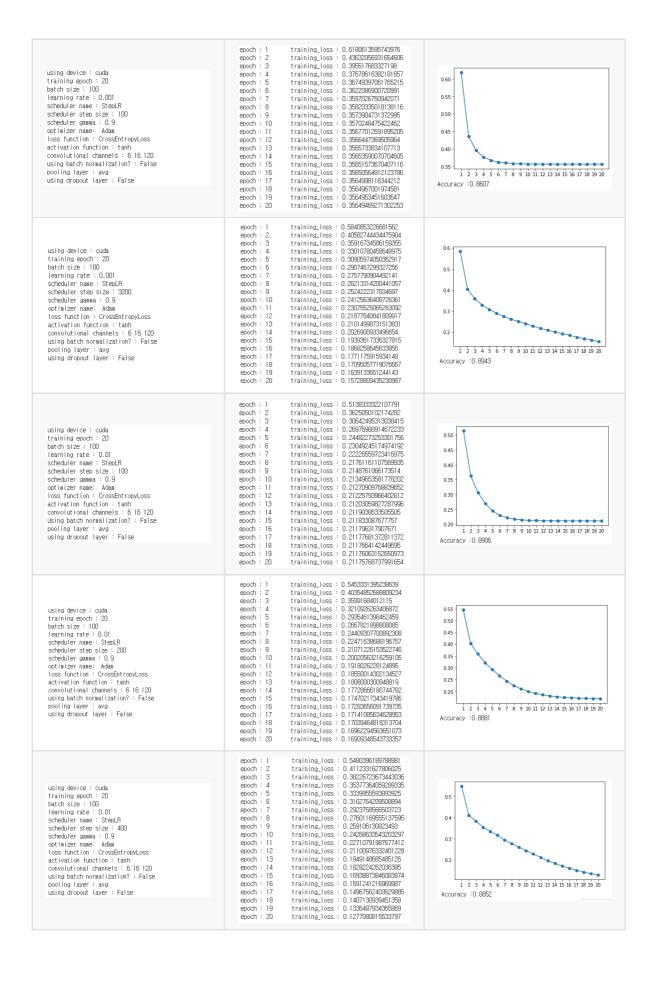
4-2-1 LeNet-5 optimizer parameter

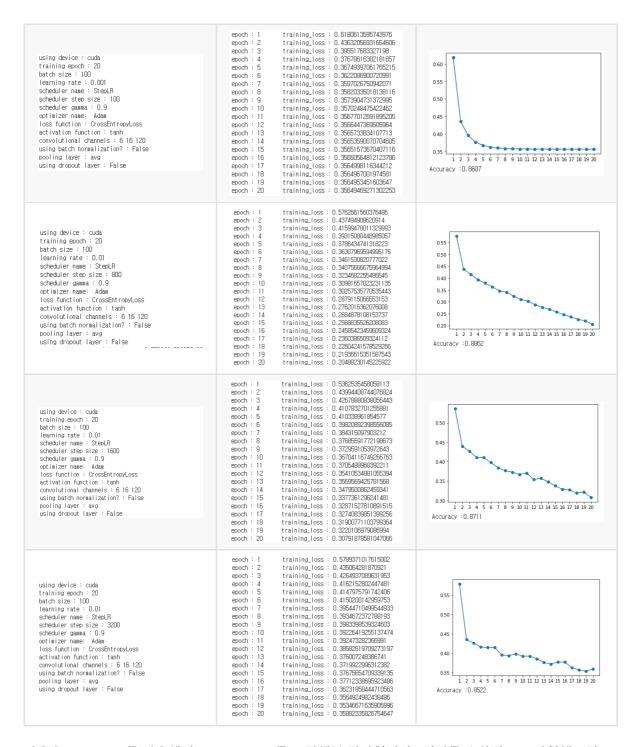
optimizer parameter - scheduler

scheduler_name=None, scheduler_step_size=None, scheduler_gamma=None,

scheduler를 사용할경우, StepLR scheduler만 적용시켜 보았고, scheduler_step_size 의 data 마다 scheduler_gamma 값을 learning rate에 곱해서 적용시키도록 했습니다.







다음은 scheduler를 사용해서 learning rate를 조정해본 결과입니다. 결과를 순차적으로 나열해보면

scheduler name: StepLR

scheduler gamma: 0.9

initial learning rate: 0.001일때

• scheduler_step_size=100 -> 최종 training loss: 0.3564, accuracy: 86.07%

• scheduler_step_size=200 -> 최종 training loss: 0.2904, accuracy: 87.95%

• scheduler_step_size=400 -> 최종 training loss: 0.2322, accuracy: 89.26%

• scheduler_step_size=800 -> 최종 training loss: 0.1902, accuracy: 89.46%

• scheduler_step_size=1600 -> 최종 training loss: 0.1720, accuracy: 89.55%

scheduler_step_size=3200 -> 최종 training loss: 0.157264, accuracy: 89.43%

scheduler name: StepLR

scheduler gamma: 0.9

initial learning rate: 0.01 일때

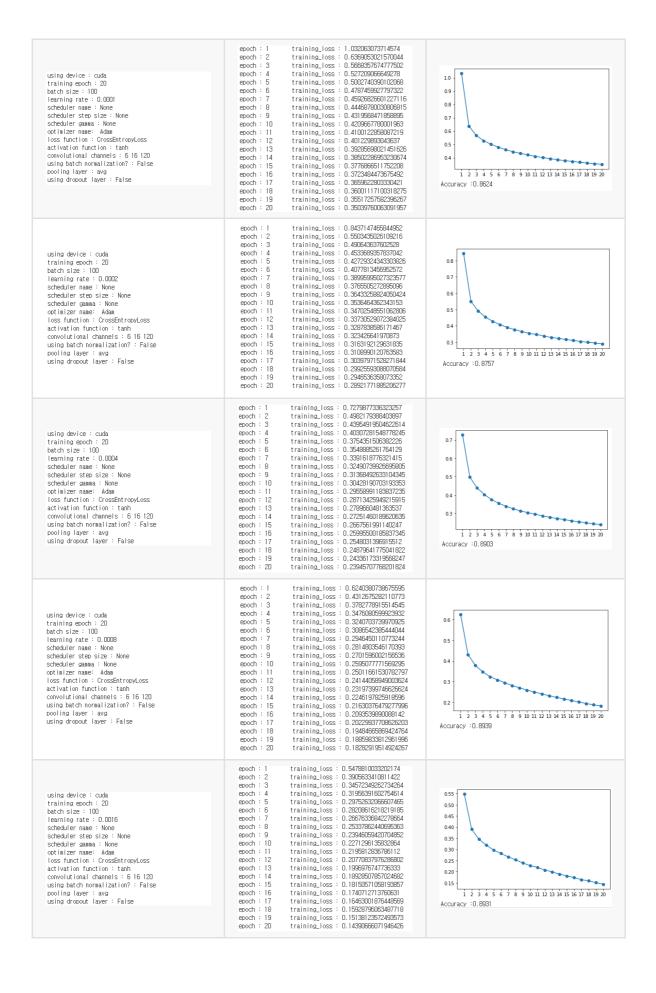
- scheduler_step_size=100 -> 최종 training loss: 0.2117, accuracy: 89.06%
- scheduler_step_size=200 -> 최종 training loss: 0.1690, accuracy: 88.81%
- scheduler_step_size=400 -> 최종 training loss: 0.1277, accuracy: 88.52%
- scheduler_step_size=800 -> 최종 training loss : 0.2048, accuracy : 88.62%
- scheduler_step_size=1600 -> 최종 training loss: 0.3079, accuracy: 87.11%
- scheduler_step_size=3200 -> 최종 training loss: 0.3588, accuracy: 85.22%

와 같이 최종 training loss 와 accuracy가 나왔습니다. 초기 learning rate가 0.001일때, scheduler step size를 100에서부터 시작해 3200까지 2배씩 증가시켜본 결과, 초기에 training loss 는 점차 줄어들었고, accuracy 는 점차 올라가다가 더이상 안올라가는 양상을 보였습니다. 초기 learning rate가 0.01 일때는, 동일하게 scheduler step size를 증가시켜본 결과, loss 는 내려갔다가 올라갔으며, accuracy는 점차 내려가는 양상을 보였습니다.

optimizer parameter - learning rate

learning_rate=0.001,

기본적으로 learning rate는 0.001 로 설정되었으며, learning rate를 조정해 가며 학습양상을 관찰해 보았습니다.





다음은 learning rate를 조정해가며 training loss 와 accuracy를 관찰해본 결과입니다. 결과를 순차적으로 나열해보면,

• learning rate: 0.0001 -> 최종 training loss: 0.3503, accuracy: 86.24%

• learning rate : 0.0002 -> 최종 training loss : 0.2892, accuracy : 87.57%

• learning rate : 0.0004 -> 최종 training loss : 0.2394, accuracy : 89.03%

• learning rate : 0.0008 -> 최종 training loss : 0.1828, accuracy : 89.39%

• learning rate: 0.0016 -> 최종 training loss: 0.1439, accuracy: 89.31%

• learning rate : 0.0032 -> 최종 training loss : 0.1794, accuracy : 88.74%

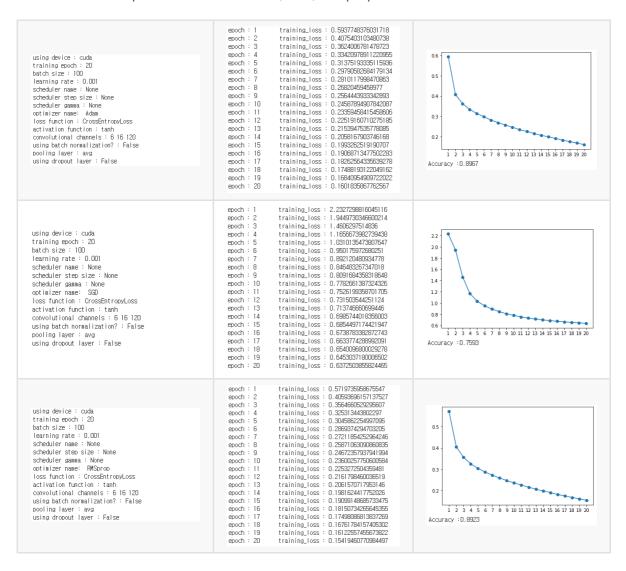
learning rate: 0.0064 -> 최종 training loss: 0.3018, accuracy: 87.41%

• learning rate : 0.0128 -> 최종 training loss : 0.4886, accuracy : 81.36%

learning rate를 0.0001서부터 0.0128까지 2배씩 증가시키면서 실행을 시켰으며, training loss 는 내려가다가 올라가는 양상을, 그리고 accuracy 는 올라가다가 내려가는 양상을 보였습니다.

optimizer_name='Adam',

기본적으로 Adam optimizer가 설정되어 있고, SGD, RMSprop을 사용할 수 있습니다.



각각의 optimizer를 사용한 결과들을 나열해보면,

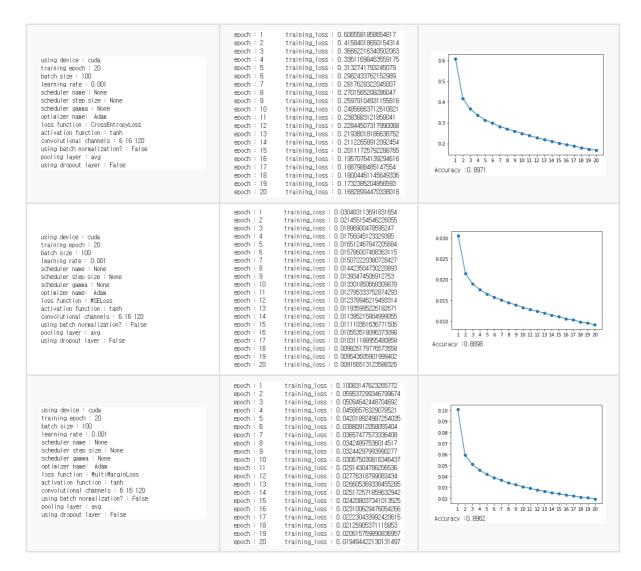
- Adam optimizer -> 최종 training loss: 0.1601, accuracy: 89.67%
- SGD optimizer -> 최종 training loss: 0.6372, accuracy: 75.93%
- RMSprop optimizer -> 최종 training loss: 0.1541, accuracy: 89.23%

로 결과가 나왔고, Adam optimizer 를 이용할때, 가장 높은 accuracy가 나왔고, SGD optimizer에서 가장 낮은 최종 training loss와 accuracy, 그리고 RMS prop에서는 가장 낮은 최종 training loss와 두번째로 낮은 accuracy가 나왔습니다.

4-2-2 LeNet-5 loss function

loss_function_name='CrossEntropyLoss',

기본적으로 loss function은 CrossEntropyLoss로 설정되어 있고, MSELoss, MultiMarginLoss를 사용할 수 있습니다.



각각의 loss function들에 대한 결과들을 나열해보면

- CrossEntropyLoss -> 최종 training loss: 0.1682, accuracy: 89.71%
- MSELoss-> 최종 training loss: 0.0091, accuracy: 88.98%
- MultiMarginLoss-> 최종 training loss: 0.0194, accuracy: 89.62%

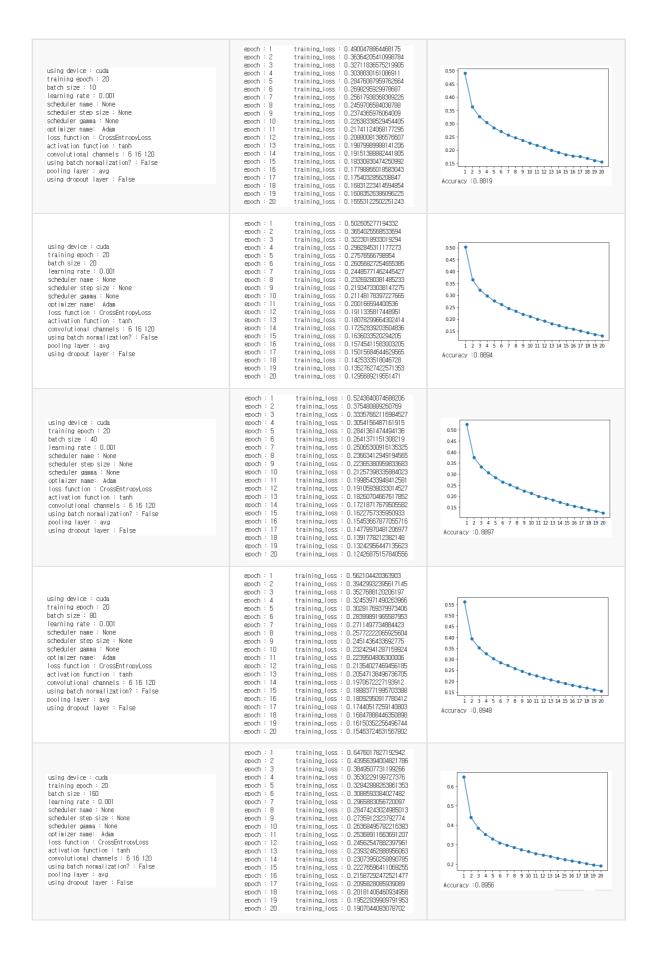
로 결과가 나옵니다.

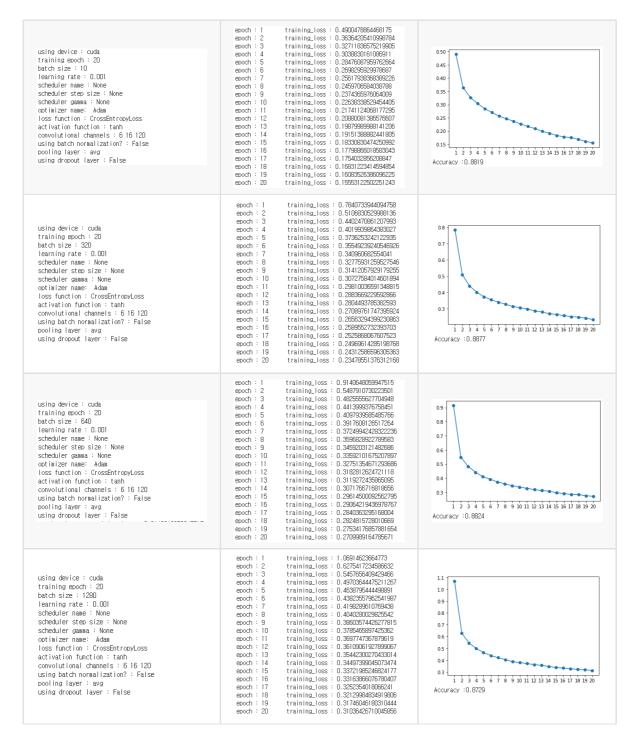
각각의 다른 loss function을 적용시켰기 때문에, training loss의 비교는 모델의 학습정도와 상관관계가 없기 때문에 accuracy만 비교해보면, CrossEntropyLoss가 가장 높은 accuracy를 보이며, 그다음으로는 MultiMarginLoss, 마지막으로는 MSELoss 가 가장 낮은 accuracy를 보였습니다.

4-2-3 LeNet-5 batch size

batch_size=100,

기본적으로 설정되어 있는 batch size는 100이며, batchsize를 조정해가며 학습 양상을 관찰해봤습니다.





batch size를 10에서부터 1280까지 2배식 증가시키며 학습을 해보았고, 결과를 순차적으로 나열해 보면

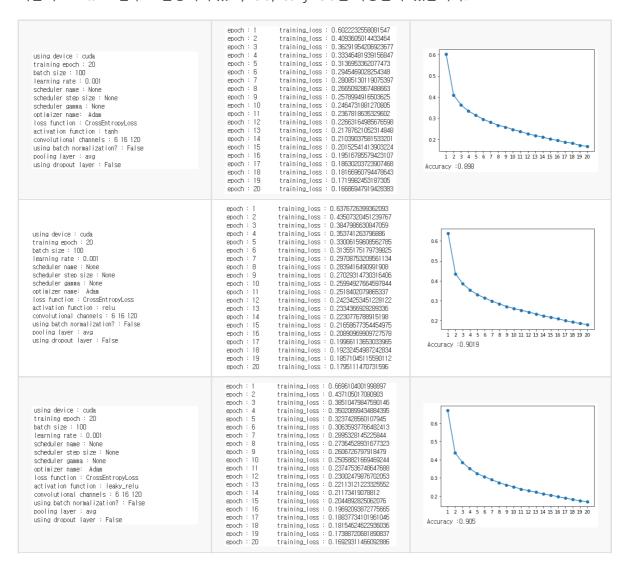
- batch size: 10 -> 최종 training loss: 0.1555, accuracy: 88.19%
- batch size : 20 -> 최종 training loss : 0.1295, accuracy : 88.94%
- batch size: 40 -> 최종 training loss: 0.1242, accuracy: 88.97%
- batch size: 80 -> 최종 training loss: 0.1546, accuracy: 89.48%
- batch size : 160 -> 최종 training loss : 0.1907, accuracy : 89.56%
- batch size: 320 -> 최종 training loss: 0.2347, accuracy: 88.77%
- batch size : 640 -> 최종 training loss : 0.2709, accuracy : 88.24%
- batch size : 1280 -> 최종 training loss : 0.3103, accuracy : 87.29%

로 결과가 나옵니다. batch size를 증가시킬수록 최종 training loss 는 커지는 양상을 보이고, accuracy 는 올라갔다가 내려가는 양상이 나타났습니다.

activation function

activation_function='tanh',

기본적으로 tanh 함수로 설정되어 있고, relu, leaky relu를 사용할 수 있습니다.



순차적으로 activation function으로 tanh, relu, leaky relu 함수를 써봤고, 결과를 나열해 보면,

- tanh function -> 최종 training loss: 0.1668, accuracy: 89.8%
- relu function -> 최종 training loss: 0.1795, accuracy: 90.19%
- leaky relu function -> 최종 training loss: 0.1692, accuracy:90.5%

로 결과가 나옵니다. leaky relu에서 가장 높은 accuracy가 나왔고, 그 다음으로 relu 에서, 그리고 마지막으로 tanh 에서 가장 낮은 accuracy가 나왔습니다.

pooling layer

pooling_layer='avg',

기본적으로 average pooling layer로 설정되어 있고, max pooling layer('max') 로 설정 할 수 있습니다.

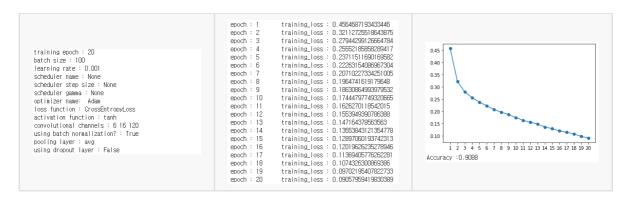


max pooling layer를 적용해본 결과, accuracy는 90.82%로 기존의 average pooling layer를 사용한 base case에 비해 높게 나왔습니다.

batch normalization

use_batchnorm=False,

기본적으로 batch normalization layer를 사용하지 않고, 설정으로 True로 넘겨주면 batch normalization layer가 추가되게 됩니다.



batch normalization을 추가해본 결과, base case의 accuracy (89.24%) 에 비해 향상된 accuracy, 90.88%가 관측되었습니다.

dropout

use_dropout=False):

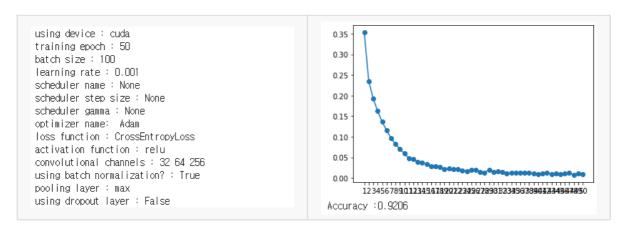
기본적으로 dropout 기법을 사용하지 않으며, 설정으로 True를 넘겨주면 첫번째 fully connected layer 에 dropout을 적용시킬 수 있게 하였습니다.

```
training_loss
                                                                                                                                         training_loss
training_loss
training_loss
training_loss
                                                                                                             epoch
                                                                                                                                                                      0.44898925987382704
                                                                                                             epoch
epoch
epoch
                                                                                                                                                                      0.39537846418718525
using device : cuda
training epoch : 20
batch size : 100
learning rate : 0.001
                                                                                                                                                                      0.36487800747156146
0.3447611017773549
0.3296039090802273
                                                                                                             epoch
                                                                                                                                          training_loss
                                                                                                             epoch
                                                                                                                                          training loss
                                                                                                                                                                      0.3141102272147935
 scheduler name : None
scheduler step size : None
scheduler gamma : None
                                                                                                             epoch
epoch
epoch
                                                                                                                                          training_loss
training_loss
training_loss
training_loss
                                                                                                                                                                      0.30269648113598435
                                                                                                                                                                      0.2906275656570989
0.2813079141825433
optimizer name: Adam
loss function: CrossEntropyLoss
activation function: tanh
convolutional channels: 6 16 120
using batch normalization?: False
                                                                                                             epoch
                                                                                                                                          training_loss
                                                                                                                                                                      0.27341642474134775
                                                                                                             epoch
                                                                                                                                          training_loss
                                                                                                                                                                      0.26201685659587376
                                                                                                                                                                                                                                   0.3
                                                                                                             epoch
epoch
epoch
                                                                                                                                          training_loss
training_loss
training_loss
                                                                                                                                                                      0.25292652030785867
                                                                                                                                                                      0.24665122659256072
0.2372478244329492
pooling layer : avg
using dropout layer : True
                                                                                                             epoch
                                                                                                                                          training_loss
                                                                                                                                                                      0.23030539847910392
                                                                                                                                                                                                                                            1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
                                                                                                                                         training_loss:
training_loss:
training_loss:
training_loss:
                                                                                                             epoch
                                                                                                                                                                      0.22527634012202397
                                                                                                                                                                                                                                  Accuracy : 0.8976
                                                                                                             epoch
epoch
epoch
                                                                                                                                                                      0.2184324014311036
                                                                                                                                                                      0.21321125507354746
0.20521317571401618
```

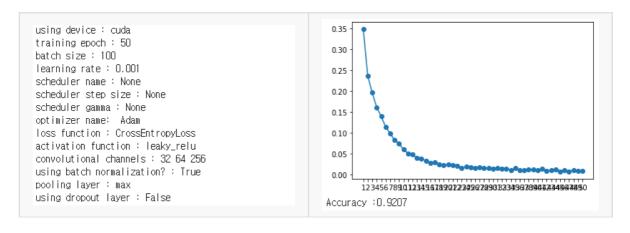
추가해본 결과, base case에비해서 accuracy는 89.76%로 향상된 결과가 나왔으며, 최종 training loss는 기존에 비해 0.2052로 더 높게 나왔습니다.

Setting many parameters at once

위에서 parameter를 하나씩 조정해본 결과들을 참고해서, 결과가 잘 나온 parameter들을 동시에 한번에 조정해서 학습정도를 관찰해봤습니다.



위와 같이 convolutional channel size를 각각 32, 64, 256으로 주고 max pooling layer를 사용, batch normalization layer를 사용, 그리고 relu를 activation function으로 사용한 결과 accuracy가 92.06%까지 나왔고, training loss는 0.0098까지 떨어졌습니다.



위와 같이 설정한 상태에서는 92.07%까지 accuracy가 나왔고, training loss는 0.0096떨어졌습니다.

5. Difference between Fully connected Network and LeNet-5

Fully connected network에서는 fully connected layer로만 연결되어 있기 때문에 overfitting이 쉽게 일어날 수있다는 단점이 있고, image의 spatial feature에 대한 abstraction을 하지 않는다.

LeNet-5과 같은 경우 LeNet-5가 처음으로 소개된 경우의 모델을 보면, convolutional layer를 통해서 spatial feature에대한 abstraction도 진행하고, average pooling layer를 통해서 data의 크기도 줄이지만, convolutional filter에서 channel size가 충분하지 않고, 마지막 두개의 fully connected layer에서 dropout 기법을 적용시키지 않아 overfitting될 가능성이 있어 fully connected network에 비해

accuracy가 낮게 나왔습니다 (89.24%<89.4%).

하지만 LeNet-5에서 convolutional channel size를 조정하고, activation function을 leaky relu function으로 바꾸고, average pooling layer 대신 max pooling layer 를 사용하고, batch normalization을 진행한 결과 92.07%까지 accuracy를 올릴 수 있었습니다.

6. Analysis of effects of optimizer parameters, loss function, batch size, activation function, pooling layer, convolutional channel size, batch normalization, dropout layer

optimizer parameter - scheduler

scheduler 같은 경우에는 특정 몇개의 data를 통과할때마다 learning rate에 상수를 곱해주는 StepLR scheduler를 사용해 봤습니다. scheduler를 적용시켜본 결과, learning rate를 너무 빨리 줄일 경우, learning rate가 너무 작아져서 training loss가 안줄어드는 현상이 발생했으며, learning rate 를 너무 안 줄인 경우, 학습이 잘 되지 않는 현상이 발생했습니다.

scheduler 같은 경우 현재 training loss가 어떠한 방식으로 줄어드는지를 염두에 안두고, 몇개의 data가지나갈때마다 learning rate에 상수를 곱하는 방식으로 learning rate를 조정하기 때문에 training loss는 더 낮게 나오는 경우는 있어도, accuracy가 눈에 띌 정도로 올라가지는 않았습니다. 좀더 세밀하게 조정하기 위해서는 현재 training loss를 추적하면서, loss가 갑자기 내려가는 정도가 낮아질 경우, learning rate를 조정하는 방식이 accuracy 향상에 더 효율적일 것 같습니다.

optimizer parameter - learning rate

learning rate 같은 경우 너무 낮은 경우, training loss가 잘 안줄어들고, 학습이 진전이 잘 안되었습니다. learning rate가 너무 큰경우, loss function에서의 minimum 값을 잘 찾지 못해 training loss가 다음 epoch에서 증가하는 현상까지 일어났습니다.

여러가지 learning rate로 실험해본 결과, 0.0008일때 accuracy가 89.39%로 가장 높게 나왔습니다.

optimizer parameter - optimizer type

optimizer type 같은 경우 SGD, RMSProp, Adam optimizer를 사용해봤고, SGD optimizer 같은 경우에는 high computation의 문제와 saddle point에 대해서 벗어나지 못할 가능성이 있습니다, 이러한 문제점을 해결하기 위해 순차적으로 나온 개선 optimizer가 RMSProp, Adam optimizer고, 예상한 바와 같이 순서대로 SGD는 가장 낮은 accuracy를, Adam는 가장 높은 accuracy를 나타냈습니다.

loss function

loss function 은 MSELoss, MultiMarginLoss, CrossEntropyLoss를 사용해봤습니다. MSELoss 같은경우 target class에 해당하는 one hot encoding tensor와 model output data의 softmax tensor의 거리의 제곱만을 고려했기 때문에 다른 loss 들에 비해 낮은 accuracy가 나왔습니다. MultiMarginLoss 같은 경우, input 과 target의 뺀값이 margin보다 낮은경우 loss를 0으로 취급하기 때문에 학습 결과 CrossEntropyLoss에 비해 낮은 accuracy가 나왔습니다. 마지막으로 CrossEntropyLoss 같은 경우에 probability distribution에 관한 distance를 측정하기 때문에 가장 높은 accuracy가 나왔습니다.

batch size

batch size 가 너무 작은 경우에, 일단 모델을 학습시키는데에 오래 걸리고, 너무 small batch에 대해서 학습을 진행하기 때문에 sample bias가 존재합니다. 하지만 large batch를 사용할 경우, overfitting 이 더 잘 발생합니다. 이러한 점에서 적당한 batch size를 이용하는게 좋으며, 여러가지 실험해본 결과 160 일때 최고의 accuracy가 나왔습니다.

activation function

activation function으로는 tanh, relu, leaky relu function을사용해봤습니다. tanh function 같은 경우양단에서 기울기가 급격하게 0으로 수렴하는 현상 때문에 gradient descent에서 문제점이 발생합니다. relu function 같은 경우 값이 0인 구간으로 인해 weight initialization을 잘못 할 경우, 평생 출력값이 0일수 있는 문제점이 발생합니다. 이러한 문제점을 해결하기 위해 결과값이 0인 범위에 대해 작은 기울기를 준 함수가 leaky relu 입니다. 차례대로 개선된 만큼 tanh, relu, leaky relu순으로 높은 accuracy가 나왔습니다.

pooling layer

pooling layer 같은 경우 average와 max pooling layer를 사용해봤으며, max pooling layer에서 더 높은 accuracy가 나왔습니다. 이러한 이유는 down sampling하는 과정에서 평균을 구하는것보다 space를 대표하는 가장 큰 값을 뽑는게 더 좋기 때문입니다.

convolutional channel size

convolutional channel size는 기존에 6,16,120 이외에 32, 64, 256으로 channel size를 조정해 보았고, 더 높은 accuracy를 보였습니다. 높은 channel 갯수를 통해서 더 많은 feature들에 대한 학습을 진행할 수 있어서 더 높은 accuracy가 나왔습니다.

batch normalization

layer에서 layer로 전해지는 값들이 너무 크거나 작을 경우, gradient descent를 할때 문제가 생깁니다. 이를 방지하기 위해서 batch normalization을통해 값들을 조정할 경우 더 높은 accuracy가 나왔습니다.

dropout layer

fully connected layer 같은 경우 weight가 너무 많아서 training data에서만 학습이 잘 되는 현상인 overfitting의 문제점이 일어날 수 있습니다. 이를 위해서 drop out 기법을 통해서 일정확률로 neuron의 output data를 0으로 만들어주는 dropout layer를 추가하면 overfitting 현상을 해결할 수 있습니다.